回归拟合实验报告

结论

- 最小二乘法、梯度下降法与牛顿法在线性回归上的最终误差几乎一致，说明三者收敛到同一最优解。
- 多项式回归能改善拟合，但复杂度继续升高时测试误差回升，阶数过高的时候出现典型过拟合。
- 三角基函数回归在本实验中表现最好：freq = 9 时测试集 MSE 最低，为 0.4029。

1 实验任务与实现概览

首先比较最小二乘法、梯度下降法和牛顿法在线性模型上的训练误差与测试误差；随后在发现线性模型欠拟合后，继续尝试非线性模型，并从“模型选择理由—实验结果—结果分析”三个层面回答第二问。

代码实现点	说明
线性部分	三种方法共享一次线性模型 y = b + wx；GD 采用零初始化、学习率 0.01、迭代 1000 次；牛顿法基于 Hessian 更新。
非线性部分	多项式模型测试 degree = 1, 2, 3, 4, 5, 12；三角基模型测试 freq = 1 至 20。
求解方式	多项式与三角基回归都先做特征展开，再在线性参数空间内用最小二乘法求解。

2 问题一：线性模型拟合

一次线性模型形式为 $y = b + wx$。由于均方误差目标是凸二次函数，最小二乘法、梯度下降法和牛顿法理论上都应收敛到同一个全局最优解。图 1 中三组柱形几乎完全重合，也验证了这一点。

从结果上看，三种求解方法的训练误差与测试误差几乎相同；差别主要体现在求解过程，而不是最终模型质量。与此同时，测试集 MSE 仍约为 0.595，说明一次线性函数只能刻画整体趋势，无法捕捉数据中的局部波动。

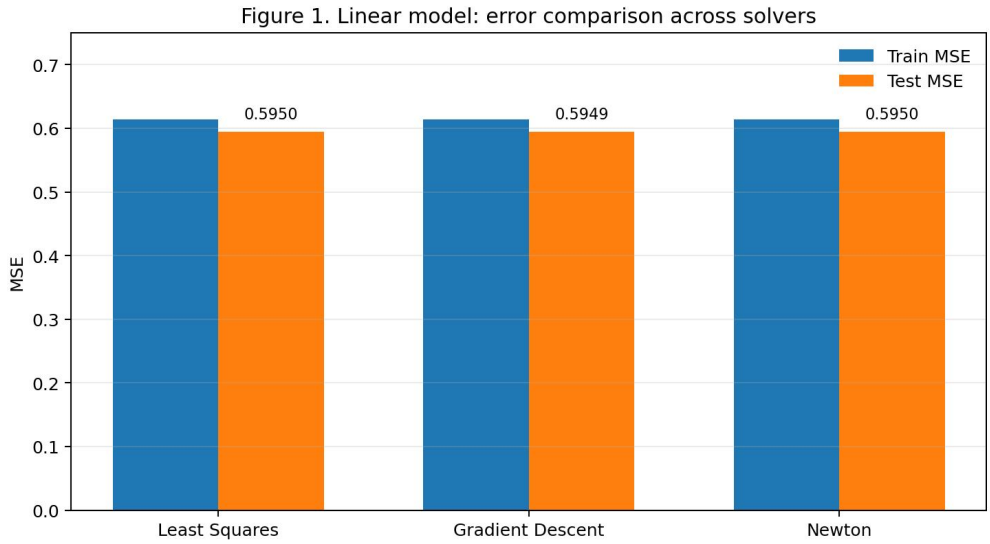

图 1　线性模型三种求解方法的误差对比。三种方法最终误差几乎一致。

3 问题二：非线性模型拟合

从问题一可见，线性模型存在明显欠拟合，因此第二问需要寻找更合适的非线性模型。这里先将多项式回归作为候选方案，再结合数据中的波动特征，选择三角基函数回归作为最终模型。

3.1 多项式回归：作为候选模型

多项式回归通过增加幂次项提高表达能力。图 2 表明：训练误差随着阶数上升而持续下降，但测试误差并不单调下降，而是在 degree = 5 时达到最低点 0.5151，之后回升。这说明更高的复杂度并不必然带来更好的泛化性能。

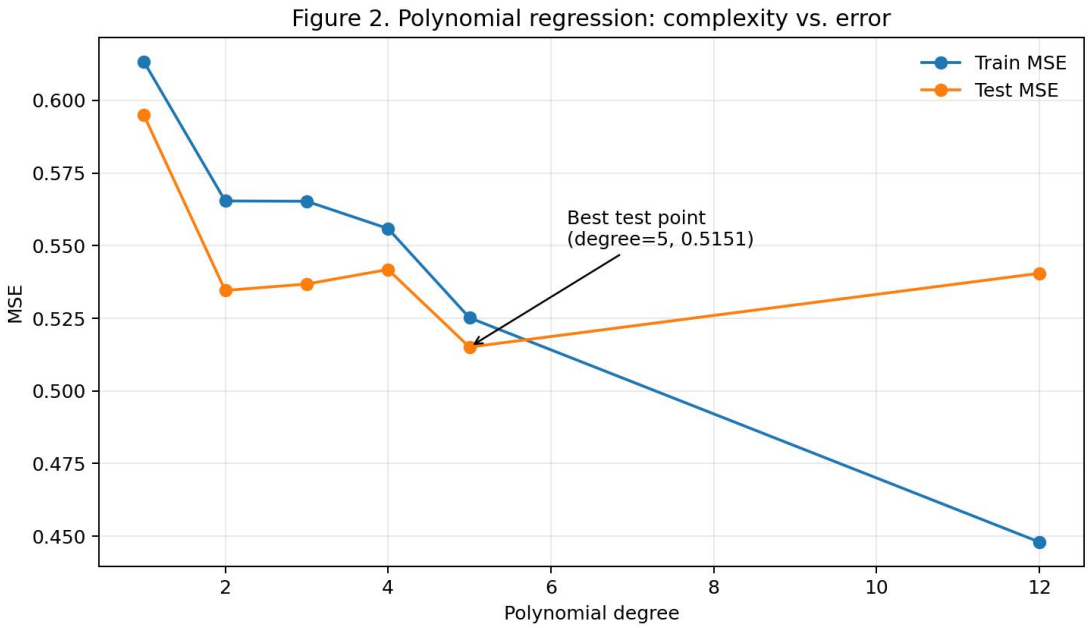

图 2 多项式回归中，训练误差随复杂度增加而下降，但测试误差在最优点后回升。

3.2 三角基函数回归：最终选用模型

代码中三角基函数模型在常数项与线性项之外，进一步加入 sin(kx)与 cos(kx) 基底（类似傅里叶级数），并对展开后的特征矩阵继续使用最小二乘法求解。这样既保留了线性参数求解的稳定性，又提升了模型对振荡结构的表达能力。

图 3 显示：当频率数增加时，训练误差持续下降，但测试误差在 freq = 9 时达到最优值 0.4029，随后开始回升。由此可见，三角基模型比多项式更贴合当前数据的波动结构。

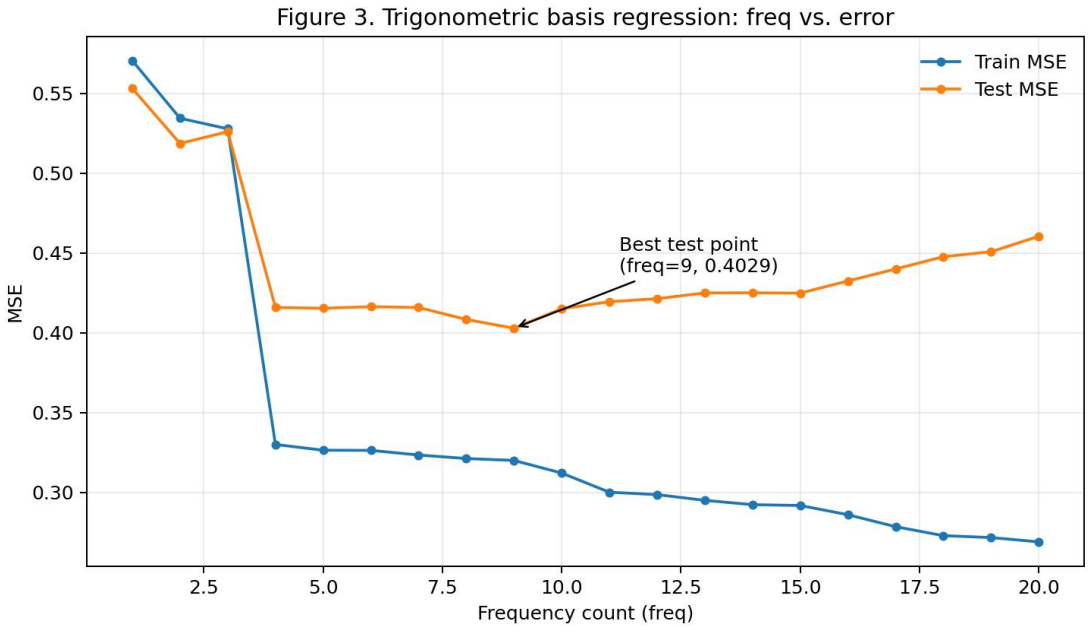

图 3 三角基函数回归的误差曲线。freq = 9 时测试集 MSE 最低。

3.3 横向比较与最终判断

图 4 汇总了三类模型的最佳测试误差。与一次线性模型相比，多项式模型已经显著降低误差；而三角基函数模型进一步把测试 MSE 降至 0.4029，成为本实验表现最好的模型。这一结果印证了数据内在具有周期性振荡特征。但是很难找到能严格拟合出来的解析式，因为 train 和 test 数据的规律并不具备常规的线性关系，且噪声分布不完全一致。

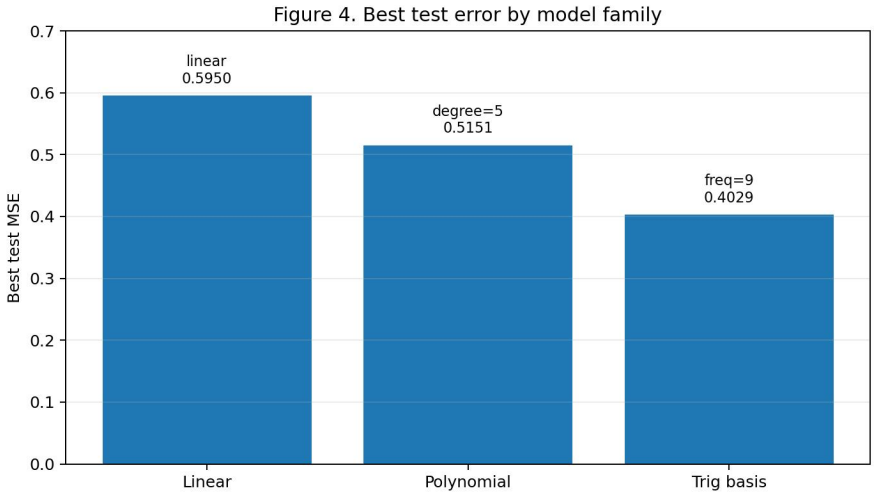

图 4 三类模型最佳测试误差比较。三角基函数模型取得最低测试误差。

4 结论

在线性回归问题上，最小二乘法、梯度下降法和牛顿法虽然求解方式不同，但最终都会收敛到同一个线性最优解，因此误差几乎一致。进一步引入非线性基函数后，多项式回归可以改善拟合，但高阶时泛化能力下降；三角基函数回归更匹配当前数据中的周期性特点，并在 freq = 9 时取得最低测试集 MSE 0.4029。另外，RBF 回归也是一种常见的非线性基函数方法，也能有效缓解线性模型的欠拟合；与本文采用的正弦/余弦三角基函数相比，RBF 更偏向局部平滑拟合，而三角基函数更适合描述整体的振荡结构，因此本文最终仍以三角基函数回归作为主要结果。

备注：主代码独立完成，绘图代码 AI 辅助完成。