PRML 作业报告

3D Make-Moons 数据集上的分类模型比较

一、实验目的

本实验的目的是在一个三维非线性二分类数据集上比较不同分类方法的性能。具体比较的模型包括单棵决策树、AdaBoost 集成决策树，以及三种不同核函数的支持向量机，分别为线性核、多项式核和 RBF 核。通过比较各模型在测试集上的 Accuracy、Precision、Recall 和 F1-score，分析不同模型在该类非线性分类问题上的适用性。

二、数据集

本实验直接使用题目给出的 make_moons_3d 函数生成三维二分类数据。该数据集由两类带噪声的三维“月牙”形样本构成，类别边界明显非线性。训练集设置为 n_samples=500，因此总样本数为 1000；测试集设置为 n_samples=250，因此总样本数为 500。训练集和测试集由相同的数据生成机制得到，但随机种子不同，因此测试集可以视为与训练集同分布的新样本。

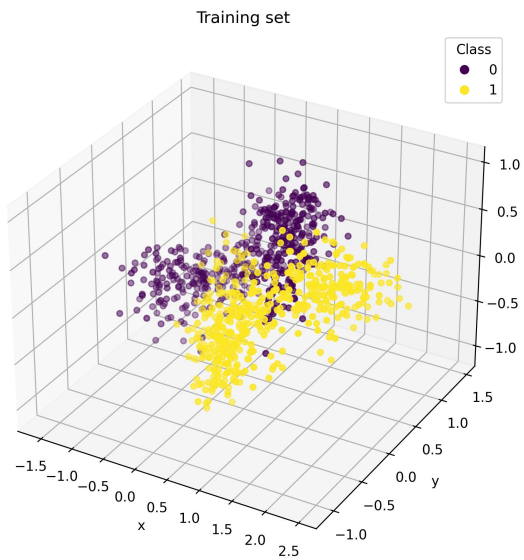

图 1 训练集三维分布示意图

三、模型与实验设置

本实验共比较 5 个模型。为了保证实验可重复，涉及随机过程的模型均固定了 random_state。

（1）Decision Tree：使用 DecisionTreeClassifier(max_depth=5, random_state=42)。将最大深度限制为 5，为了在保持一定表达能力的同时，避免树无限生长导致过拟合。

（2）AdaBoost + Decision Tree：基学习器为深度为 3 的决策树，使用 200 个弱学习器，学习率设为 1.0。AdaBoost 的思路是逐轮关注前一轮分错的样本，并将多个较弱的树组合成一个更强的分类器。

（3）SVM (Linear)：采用线性核函数，参数 C=1.0。

（4）SVM (Poly)：采用三次多项式核函数，参数为 degree=3，C=1.0，gamma="scale"，coef0=1.0。

（5）SVM (RBF)：采用 RBF 核函数，参数为 C=2.0，gamma="scale"。

由于支持向量机对特征尺度较为敏感，因此三种 SVM 模型前都加入了 StandardScaler 进行标准化处理。

四、评价指标

实验使用 Accuracy、Precision、Recall 和 F1-score 作为主要评价指标。其中 Accuracy 反映整体分类正确率；Precision 反映预测为正类的样本中有多少是真正的正类；Recall 反映真实正类中有多少被模型识别出来；F1-score 是 Precision 和 Recall 的调和平均值。此外，程序还输出了各模型的训练集准确率和混淆矩阵，用于辅助分析模型是否存在明显的欠拟合或过拟合现象。

五、实验结果

各模型在训练集和测试集上的结果如下表所示。

模型	训练准确率	测试准确率	Precision	Recall	F1-score
AdaBoost + DT	1.000	0.972	0.9758	0.9680	0.9719
SVM (RBF)	0.974	0.968	0.9643	0.9720	0.9681
SVM (Poly)	0.973	0.964	0.9640	0.9640	0.9640
Decision Tree	0.975	0.950	0.9518	0.9480	0.9499
SVM (Linear)	0.896	0.906	0.9044	0.9080	0.9062

从测试集准确率来看，性能从高到低依次为：AdaBoost + DT、SVM (RBF)、SVM (Poly)、Decision Tree、SVM (Linear)。

从结果表可以看出，不同模型之间的性能差异较为明显。AdaBoost+DT 的测试准确率最高，为 0.972；相比单棵决策树的 0.950，提高了 2.2 个百分点。RBF 核 SVM 的测试准确率为 0.968，仅比 AdaBoost 低 0.4 个百分点，但比线性核 SVM 的 0.906 高出 6.2 个百分点。这说明在该三维非线性数据集上，模型是否能够表达弯曲边界，对最终性能影响很大。

从训练集和测试集准确率的对比来看，AdaBoost+DT 在训练集上达到 1.000，在测试集上为 0.972，说明其拟合能力最强，但在当前样本规模和噪声条件下仍保持了较好的泛化能力。单棵决策树训练准确率为 0.975，而测试准确率下降到 0.950，说明它虽然可以较好地拟合训练数据，但泛化能力弱于 AdaBoost。相比之下，RBF 核和多项式核 SVM 的训练集和测试集准确率更接近，表现出更稳定的泛化性能。线性核 SVM 则在训练集和测试集上都不高，更符合模型表达能力不足所导致的欠拟合特征，而不是过拟合。

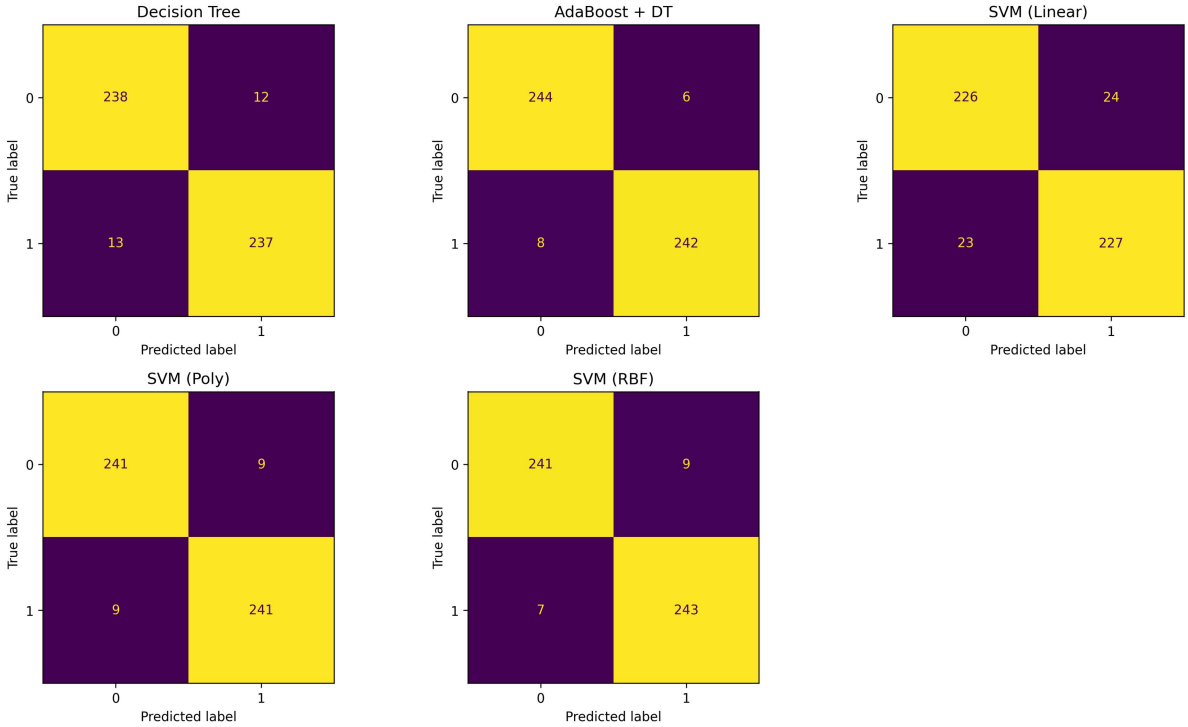

图 2 各模型在测试集上的混淆矩阵

六、结果分析

首先，线性核 SVM 的表现最差，测试准确率只有 0.906。其主要原因是该数据集的类别边界明显不是线性的，而线性核 SVM 只能学习一个线性分割超平面，因此很难刻画两类月牙形样本之间的弯曲边界。从训练准确率和测试准确率都不高这一点也可以看出，它更像是模型假设不匹配，而不是单纯的过拟合。

其次，单棵决策树的测试准确率为 0.950，明显高于线性核 SVM。这说明决策树通过递归划分特征空间，已经能够处理一定程度的非线性分类问题。不过，决策树的边界本质上是分段、局部的，对于这种连续弯曲的边界仍然存在拟合限制。

AdaBoost + DT 的性能最好，测试准确率达到 0.972。相比单棵决策树，AdaBoost 通过将多个弱学习器串行组合，不断修正前一轮错分样本对应的决策边界，因此在这个实验中取得了最好的结果。虽然它的训练准确率达到 1.000，但测试准确率也最高，说明在当前样本规模和噪声水平下，这种集成策略具有较强的泛化能力。

对于三种 SVM 而言，RBF 核和多项式核都明显优于线性核，其中 RBF 核略优于多项式核。我认为这是因为 RBF 核具有更强的局部非线性建模能力，更适合这类平滑弯曲的分类边界；多项式核虽然也能拟合非线性关系，但灵活性稍弱，因此最终结果略低于 RBF 核。

综合来看，这个实验比较清楚地说明了一点：对于非线性结构明显的数据，模型的表达能力和归纳偏置非常重要。如果模型只能给出线性边界，那么效果往往受限；而能够描述复杂边界的模型，如 Boosting 后的树模型或带合适核函数的 SVM，通常会表现更好。

七、结论

本实验在 3D Make-Moons 数据集上比较了 Decision Tree、AdaBoost + Decision Tree 以及三种核函数下的 SVM。实验结果表明，AdaBoost + DT 的综合性能最好，RBF 核 SVM 次之，多项式核 SVM 也有较好表现；单棵决策树能够处理非线性问题，但不如集成方法；线性核 SVM 由于无法有效描述弯曲边界，因此表现最弱。总体来看，对于该类非线性分类任务，能够学习复杂非线性边界的模型通常更合适。

需要说明的是，AdaBoost+DT 虽然取得了最高准确率，但它与 RBF 核 SVM 的差距只有 0.4 个百分点。因此，在该数据集上，集成树模型和合适核函数的 SVM 都能够取得较好效果，其中 AdaBoost 略优。