基于 LSTM 的空气质量预测

黄祥耘 23231088

一、实验目的

本实验的目的是使用多变量时间序列数据建立 LSTM 预测模型，根据过去若干小时的污染和天气信息预测下一小时的 PM2.5 浓度。与只使用单一污染序列相比，多变量输入可以同时利用温度、气压、露点、风向、风速、降雪和降雨等信息，因此更适合描述空气污染变化中受到多种因素共同影响的特点。

二、数据集

本实验使用 Air Quality 数据集。原始数据记录了 2010 年到 2014 年逐小时的污染和天气情况，包含时间、PM2.5 浓度、露点、温度、气压、风向、累计风速、累计降雪小时数和累计降雨小时数等字段。

在实际代码中，数据文件中的 pollution 字段作为预测目标处理，对应作业说明中的 pm2.5；wnd_dir 字段作为类别型风向变量进行编码，其余连续变量直接作为数值特征使用。最终每个时间步包含 8 个输入特征，预测目标为下一小时的 PM2.5 浓度。

三、数据预处理

首先读取 csv 文件并检查目标列是否存在。由于时间序列中存在少量缺失值，如果直接删除可能破坏时间连续性，因此本实验采用前向填充和后向填充进行处理。随后，将风向 wnd_dir 使用 LabelEncoder 转换为数值形式，并删除 date 字段，只保留参与建模的污染和天气变量。

为了避免测试集信息泄露，本实验先按照时间顺序将数据划分为训练部分和测试部分，其中前 80%作为训练集，后 20%作为测试集。归一化时只在训练集上拟合 MinMaxScaler，再使用同一组参数转换测试集。最后使用滑动窗口构造 LSTM 输入样本，本实验设置 look_back=24，即使用过去 24 小时的数据预测下一小时污染值。构造后的训练样本维度为 (31515, 24, 8)，测试样本维度为 (8760, 24, 8)。

四、模型与实验设置

本实验采用两层 LSTM 网络进行时间序列回归。输入为过去 24 小时的 8 维特征序列，LSTM 隐藏层维度设置为 64，层数为 2，并加入 dropout=0.2。LSTM 的最后一个时间步输出接入一个全连接层，最终得到下一小时 PM2.5 的预测值。

训练时使用均方误差 MSELoss 作为损失函数，优化器为 Adam，学习率设置为 0.001。主要实验参数为：look_back=24，batch_size=64，epochs=30。实验运行命令为：CUDA_VISIBLE_DEVICES=0 conda run -n vila python 3.py --data archive/LSTM-Multivariate_pollution.csv --epochs 30 --look_back 24 --batch_size 64。

五、评价指标

实验使用 RMSE、MAE 和 R2 作为主要评价指标。RMSE 对较大的预测误差更加敏感，因此可以反映模型在污染突变时的误差情况；MAE 表示平均绝对误差，更直观地反映平均预测偏差；R2 用于衡量模型对测试集污染浓度变化的解释能力。

六、实验结果

训练过程中，模型在前几个 epoch 下降较快。第 1 个 epoch 的训练损失为 0.003699，验证损失为 0.001098；第 20 个 epoch 时训练损失下降到 0.000765，验证损失为 0.000489；第 30 个 epoch 时训练损失为 0.000719，验证损失为 0.000538。总体来看，训练损失持续下降，验证损失在后期小幅波动，没有出现明显发散。

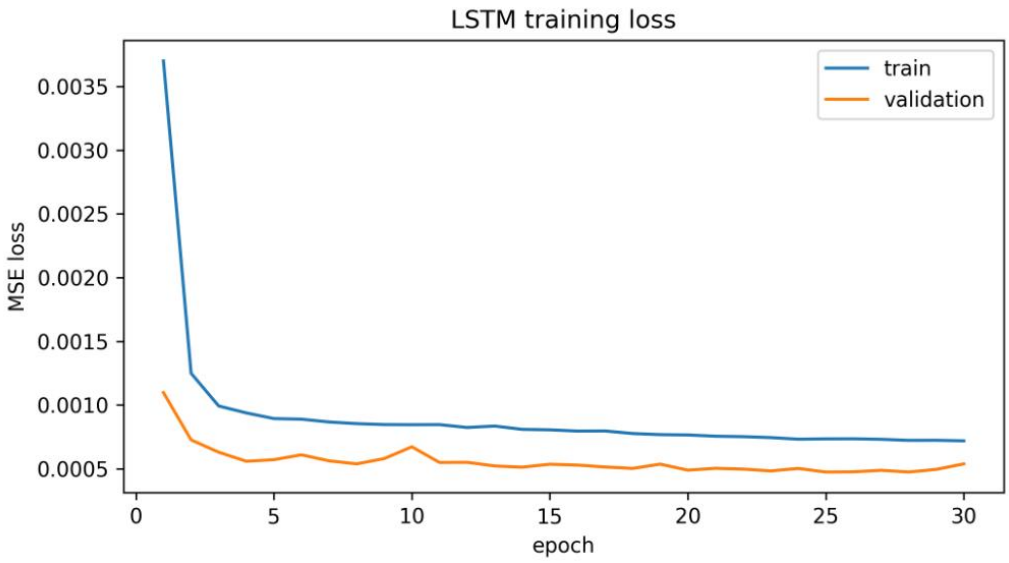

图 1 LSTM 训练损失变化曲线

模型在测试集上的最终结果如下。

指标	数值
RMSE	24.3178
MAE	13.7736
R2	0.9325

从图 2 可以看到，模型对 PM2.5 浓度的整体上升、下降趋势跟踪较好，尤其在低污染和平稳变化区间，预测曲线与真实曲线较为接近。但是在若干峰值位置，预测曲线相对真实曲线存在轻微滞后或幅值偏差。这说明 LSTM 能够学习历史窗口中的连续变化模式，但对于短时间内突然出现的污染峰值，模型更倾向于给出平滑预测。造成这种现象的原因可能是突发污染受局部排放、风向突变等外部因素影响较大，而这些因素仅通过过去 24 小时的历史序列并不一定能够完全捕捉。

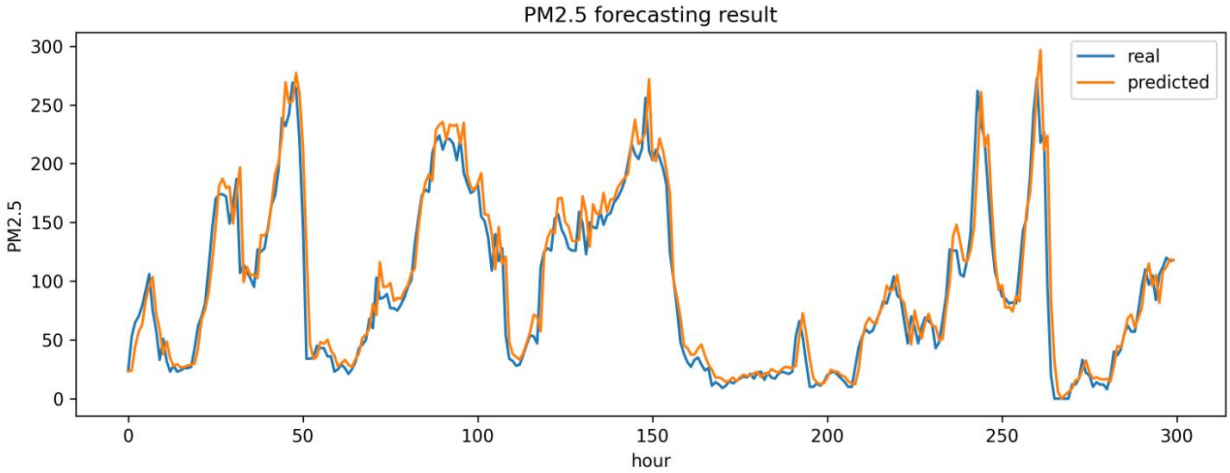

图 2 测试集前 300 小时 PM2.5 预测效果

七、结果分析

从训练损失看，模型在早期能够较快学习到污染浓度与天气变量之间的主要关系。训练到后期后，训练损失继续缓慢下降，而验证损失在 0.00047 到 0.00054 附近波动，说明模型已经基本收敛。第 30 个 epoch 的验证损失略高于第 25 个 epoch，说明继续训练可能不会带来稳定提升，后续可以考虑加入早停机制。

另外，从损失曲线可以看到，验证损失整体低于训练损失。这并不一定说明模型存在问题。一方面，模型训练阶段启用了 dropout，会在训练过程中随机丢弃部分神经元，使训练损失略高；而验证阶段 dropout 不启用，因此验证损失可能更低。另一方面，测试时段的数据分布如果相对平稳，也会使验证误差低于训练误差。因此，训练损失和验证损失的关系需要结合曲线趋势判断，而不是只比较二者大小。从当前曲线看，两者都处于较低水平，并且没有明显发散，说明模型没有出现严重过拟合。

从测试指标看，RMSE 为 24.3178，MAE 为 13.7736。RMSE 明显高于 MAE，说明模型在大多数平稳时段误差较小，但在少数污染浓度快速变化的位置会产生较大的误差。由

于 PM2.5 浓度本身具有较强波动性，突然上升或下降通常较难仅根据过去 24 小时的信息完全预测，因此这种现象是时间序列预测中比较常见的。

R2 达到 0.9325，说明模型能够解释测试集中大部分 PM2.5 浓度变化，整体拟合效果较好。结合预测曲线观察，模型对整体趋势的跟踪较稳定，对平稳阶段预测较准确；但在污染值快速变化时，预测结果可能存在一定滞后。这主要是因为 LSTM 的输入来自历史窗口，当外部环境突然变化时，模型需要依赖已有历史模式进行推断，难以立刻完全跟上突变。

总体来看，多变量 LSTM 相比简单的单变量预测具有更好的建模基础，因为污染浓度不仅与历史污染值有关，也与温度、气压、风速和降雨降雪等因素有关。不过，本实验对风向只使用了 LabelEncoder 编码，这种编码会人为引入大小顺序，未必完全符合风向的类别属性。后续可以尝试 one-hot 编码或周期性编码，以进一步观察风向特征处理方式对结果的影响。

八、结论

本实验完成了基于多变量 LSTM 的空气质量预测任务。实验使用过去 24 小时的污染和天气变量预测下一小时 PM2.5 浓度，并在测试集上取得 RMSE=24.3178、MAE=13.7736、R2=0.9325 的结果。结果表明，LSTM 能够较好地学习空气质量时间序列中的历史依赖关系，并能够利用多种天气变量辅助预测污染变化。

需要说明的是，当前模型对整体趋势的预测效果较好，但对突发污染变化仍存在一定滞后。后续可以从几个方面继续改进：一是调整时间窗口长度，比较 12 小时、24 小时和 48 小时窗口的差异；二是加入早停机制，避免后期验证损失波动；三是比较 GRU、Transformer 等模型；四是改进风向变量编码方式，进一步提升模型对气象因素的利用能力。