

模式识别作业报告

Transformer 位置编码对比实验

一、实验目的

本实验阅读并复现 Vaswani 等人在 2017 年提出的 Transformer 结构，即论文 Attention Is All You Need。原论文提出用自注意力机制替代循环神经网络和卷积结构，核心模块包括词嵌入、位置编码、多头自注意力、前馈网络、残差连接和层归一化。

选择位置编码这一方向，比较原文中的正弦位置编码、可学习绝对位置编码、简单固定绝对位置编码以及不使用位置编码时的效果，分析位置编码在 Transformer 中的必要性。

二、Transformer 核心结构复现

原论文中的 Transformer 不使用 RNN 或 CNN，而是通过注意力机制直接建模序列中任意两个位置之间的关系。缩放点积注意力可以写为：

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \text{sqrt}(d_k))V$$

其中，Q 表示 Query，K 表示 Key，V 表示 Value。 QK^T 用来计算不同 token 之间的相关性，除以 $\text{sqrt}(d_k)$ 是为了避免点积数值过大导致 softmax 分布过尖，从而影响梯度传播。

本实验在 transformer_reverse.py 中复现了缩放点积注意力、多头自注意力、逐位置前馈网络、Transformer 编码器块以及用于反转序列任务的完整模型。编码器块由自注意力、前馈网络、残差连接和 LayerNorm 组成，整体结构保留了原文 Transformer 的主要计算单元。

需要说明的是，本实验没有复现原论文中的 WMT 机器翻译大规模实验，也没有实现完整 encoder-decoder 翻译系统。本文复现的是 Transformer 的核心计算模块，并将其用于一个可控的小型序列任务，以便观察位置编码的作用。

三、实验任务设计

为了验证位置编码是否必要，本文设计了一个反转序列任务。输入是一个长度为 12 的整数序列，模型需要输出它的倒序序列。例如：

```
input = [13, 9, 14, 5, 14, 12, 1, 17, 10, 5, 1, 2]
target = [2, 1, 5, 10, 17, 1, 12, 14, 5, 14, 9, 13]
```

这个任务非常依赖位置信息。模型不仅要知道输入中有哪些 token，还要知道每个 token 处在第几个位置。若没有位置编码，自注意力层对输入位置的排列不敏感，很难判断输出第 i 个位置应该复制输入的第 $L-1-i$ 个位置。

实验设置如下表所示。

参数	数值
训练样本数	6000
验证样本数	1000
序列长度	12
词表大小	20
d_model	64
attention heads	4
encoder layers	2
batch size	128
epochs	50
optimizer	Adam
learning rate	1e-3
random seed	42

表 1 实验参数设置

四、位置编码方法

本文比较四种位置编码设置，如表 2 所示。

方法	说明
sinusoidal	原论文中的正弦/余弦位置编码，不需要训练参数
learnable	可学习绝对位置编码，每个位置有一个可训练向量
fixed_absolute	简单固定绝对位置编码，将位置编号归一化后映射到各维
none	不加入任何位置编码

表 2 位置编码对比方法

其中，sinusoidal 使用不同频率的正弦和余弦函数为每个位置生成唯一表示。它的优点是无需学习，并且天然包含多尺度的位置信息。learnable 方法直接学习每个位置的向量，在固定长度任务上通常很容易拟合。fixed_absolute 是一个较弱的对照组，它只提供简单的位置编号信息。none 则用于验证没有位置信息时 Transformer 是否仍然能完成任务。

五、实验结果

训练结果保存在 position_encoding_results.csv 中。验证集 token accuracy 曲线如下图所示。




图 1 不同位置编码方法在反转序列任务上的验证集 token accuracy

各方法的关键结果如下表所示。

位置编码	首次达到 token_acc=1.0 且 seq_acc=1.0 的 epoch	最终 token_acc	最终 seq_acc
learnable	2	1.0000	1.0000
sinusoidal	5	1.0000	1.0000
fixed_absolute	26	1.0000	1.0000
none	未达到	0.2016	0.0000

表 3 不同位置编码方法的实验结果

从图 1 和表 3 可以看到，可学习位置编码收敛最快，在第 2 个 epoch 就达到完整序列预测正确。原论文的正弦位置编码也能快速收敛，在第 5 个 epoch 达到 100% 准确率。简单固定绝对位置编码最终也能学会任务，但需要 26 个 epoch，收敛明显更慢。无位置编码时，模型训练 50 个 epoch 后 token accuracy 仍只有约 0.20，完整序列准确率始终为 0。

六、结果分析

Transformer 的自注意力机制本身擅长计算 token 之间的内容相关性，但它不会天然知道 token 的先后顺序。对于反转序列任务，输出位置和输入位置之间存在明确的镜像关系，因此模型必须知道每个 token 的位置。

实验中，none 方法长期停留在较低准确率，说明没有位置编码时模型只能利用 token 内容进行预测，而无法稳定学习“第一个输出对应最后一个输入”这种顺序规则。它偶尔能猜中一部分 token，是因为序列中可能有重复值，或者某些 token 在训练集中频繁出现，但它无法完成整条序列的精确反转。

sinusoidal 和 learnable 都能快速达到 100% 准确率，说明只要为 Transformer 注入足够清晰的位置标识，自注意力机制就可以学习位置之间的对应关系。可学习位置编码在固定长度任务上最快，因为每个位置的向量可以直接针对训练任务优化。正弦位置编码虽然不是训练得到的，但多频率 sin/cos 表示足够区分不同位置，因此也能较快收敛。

fixed_absolute 最终也能成功，说明位置编码的核心作用首先是“区分位置”。但是它收敛慢于正弦编码，说明简单线性位置编号的信息表达能力较弱，优化过程需要更多 epoch 才能学到稳定映射。相比之下，正弦位置编码通过多频率组合提供了更丰富的位置特征。

七、结论

本实验复现了 Transformer 的核心模块，并通过反转序列任务验证了位置编码的必要性。实验结果表明，自注意力机制本身不包含顺序信息，位置编码是 Transformer 处理序列任务的关键组成部分。正弦位置编码和可学习位置编码都可以有效提供位置信息，简单绝对位置编码也可行但收敛速度较慢；不使用位置编码时，模型无法完成需要精确顺序关系的任务。

因此，位置编码的核心作用是为序列中的每个 token 注入可区分的位置信息，使 Transformer 能够在注意力计算中同时利用内容关系和顺序关系。

参考文献

[1] Vaswani A., Shazeer N., Parmar N., et al. Attention Is All You Need. Advances in Neural Information Processing Systems, 2017.